

Regressão Múltipla

HO 231 – Econometria

Profa. Rosangela Ballini

Instituto de Economia - UNICAMP



Ementa

Regressão Linear Múltipla – MQO

Escalas de Medidas

Linearidade dos Coeficientes

Viés de Omissão

Análise de Variabilidade

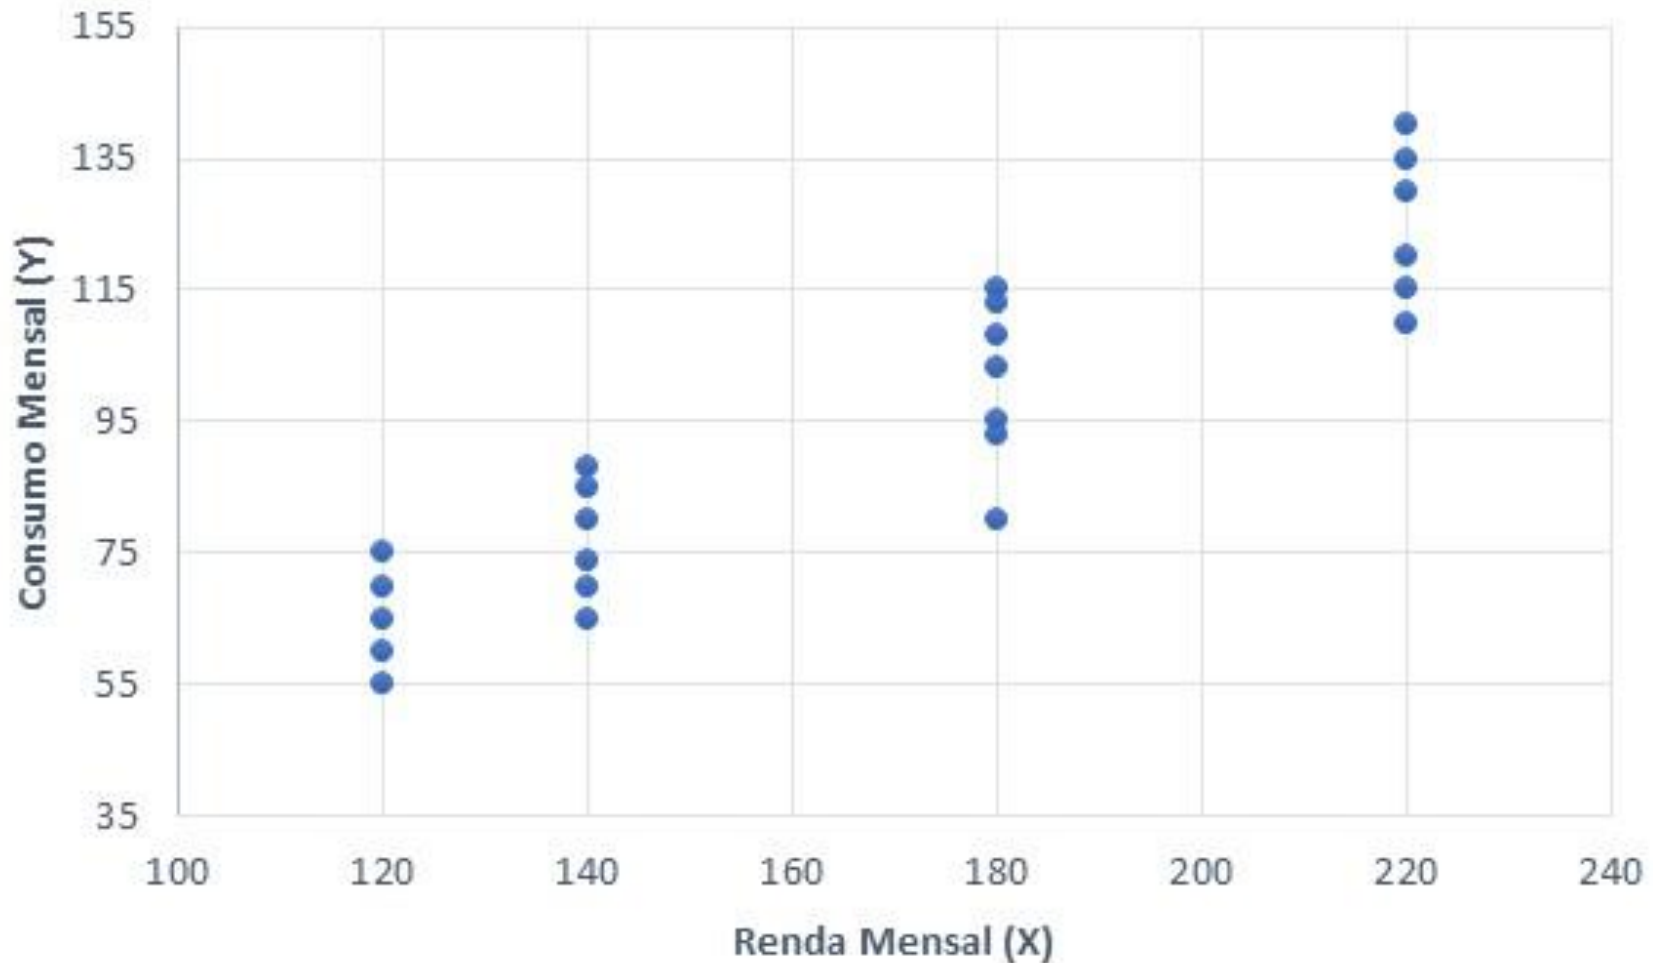
Inferência para os Coeficientes

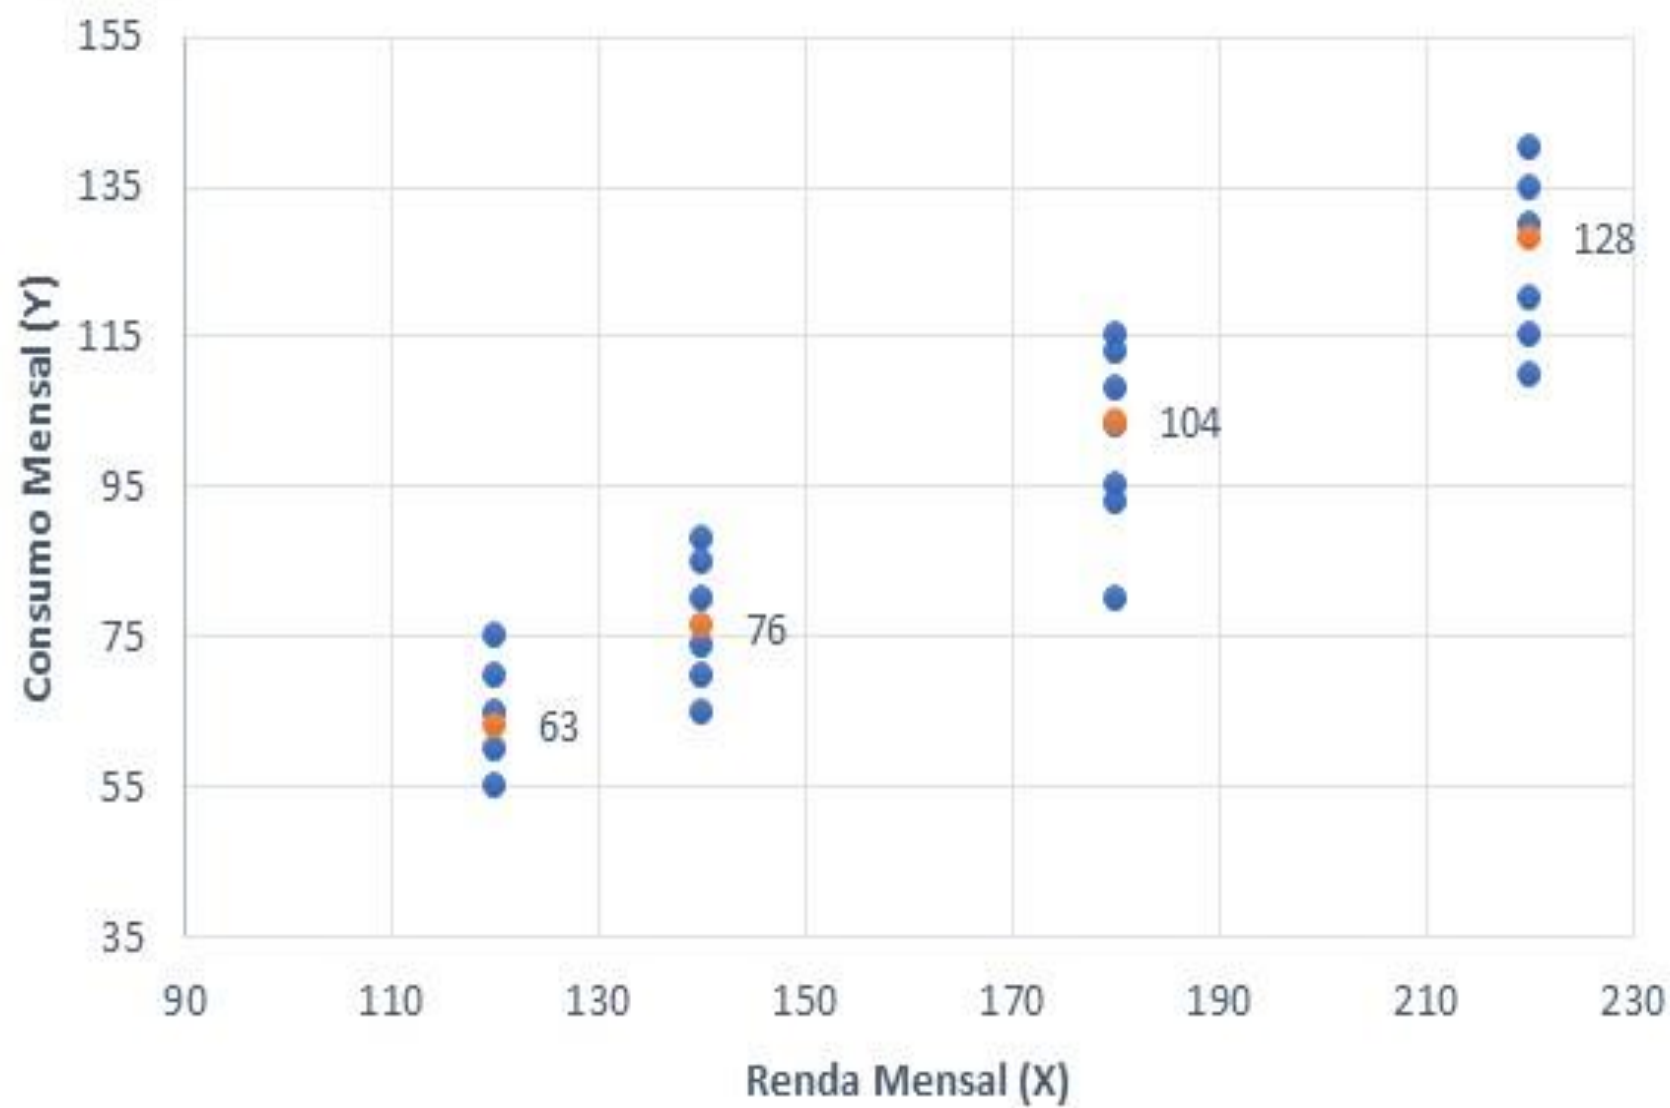
Bibliografia

Wooldridge, J. M. 2001. Introductory Econometric. Caps. 1-4.

Associação Linear

Gráfico de Dispersão





Modelo de Regressão Linear

Função Linear de Regressão Populacional (LRP)

Sejam os dados de uma população relacionados por:

$$Y_i = \beta_0 + \beta_1 X_i + u_i, \quad i = 1, \dots, N$$

sendo

Y : a variável dependente

X : variável independente

β_0 e β_1 : parâmetros

u : termo de erro

N : tamanho da população

PRESSUPOSIÇÕES DO MODELO

- 1) Lineariedade nos parâmetros;
- 2) Amostragem aleatória;
- 3) *Valor médio do erro é igual a zero:*

$$E(u_i|X) = 0$$

- 4) *Variância do erro é constante:*

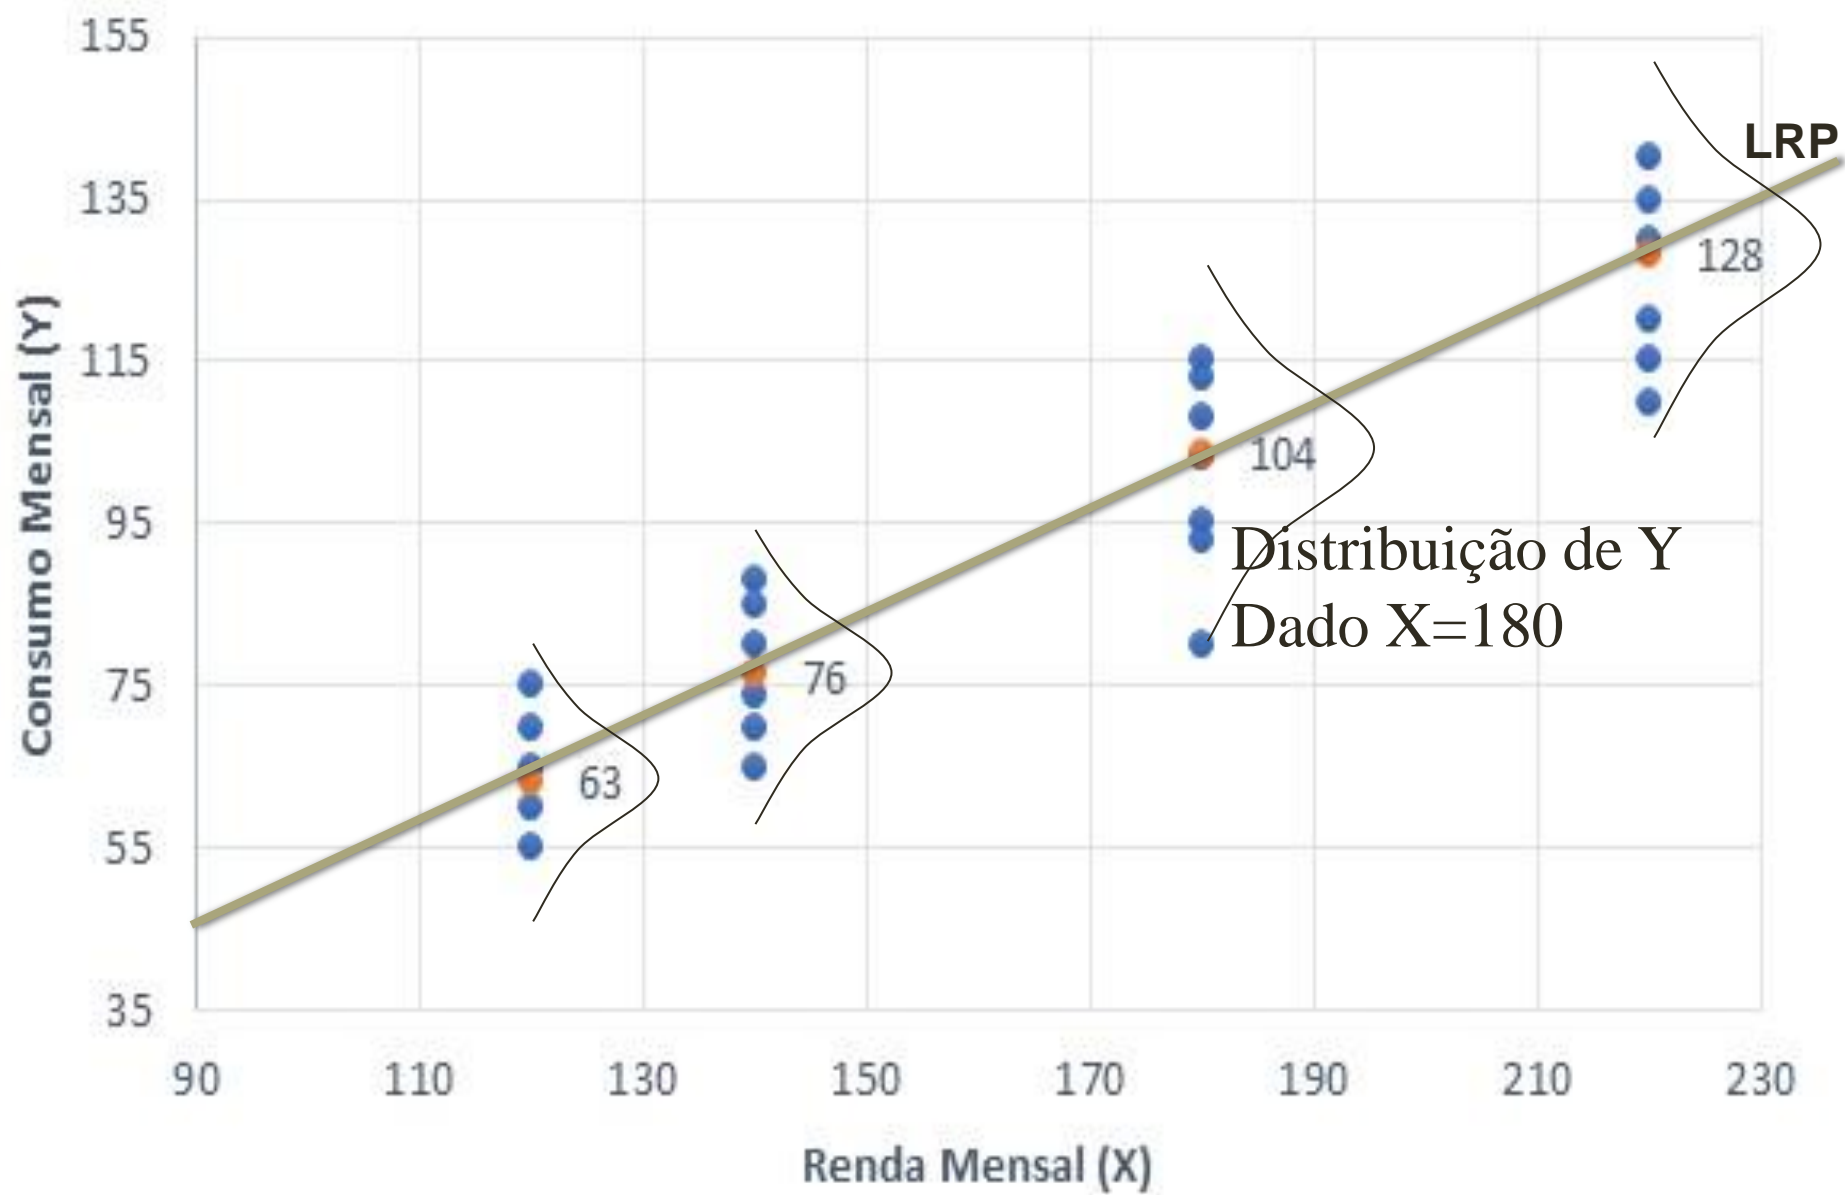
$$Var(u_i|X) = E[u_i - E(u_i)]^2 = \sigma^2$$

- 5) *Os erros não são correlacionados:*

$$corr(u_i, u_j) = 0, \text{ para } i \neq j$$

- 6) *A distribuição dos erros em torno do valor médio é Normal:*

$$u_i \sim N(0, \sigma^2)$$




Estimativas dos Parâmetros

Como o modelo de regressão populacional

$$Y_i = \beta_0 + \beta_1 X_i + u_i, \quad i = 1, \dots, N$$

não é diretamente observável, nós devemos estimá-lo a partir do modelo de regressão amostral:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + \hat{e}_i, \quad i = 1, \dots, n$$



Função de Regressão Amostral

Função de regressão amostral: $Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + \hat{e}_i$

Y previsto pelo ajuste: $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$

Resíduo: $\hat{e}_i = Y_i - \hat{Y}_i$

Função de Erro Quadrático Total (EQT):

$$EQT = \hat{e}_1^2 + \hat{e}_2^2 + \dots + \hat{e}_n^2$$

$$EQT = (Y_1 - \hat{Y}_1)^2 + (Y_2 - \hat{Y}_2)^2 + \dots + (Y_n - \hat{Y}_n)^2$$

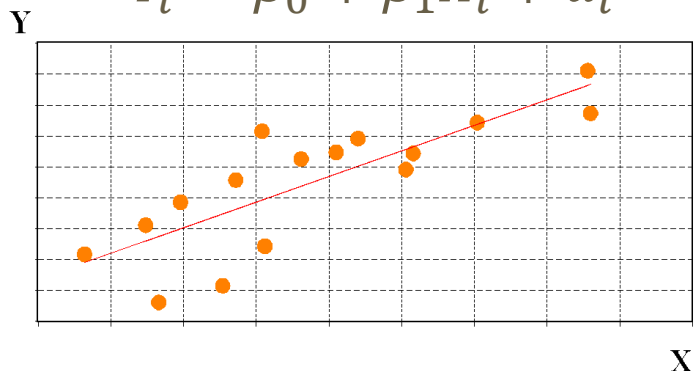
$$EQT = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

$$EQT = \sum_{i=1}^n (Y_i - (\hat{\beta}_0 + \hat{\beta}_1 X_i))^2$$

Mínimos Quadrados Ordinários

Regressão Linear Simples:

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$



$$EQT = \sum_{i=1}^n (Y_i - (\hat{\beta}_0 + \hat{\beta}_1 X_i))^2$$

Minimizando EQT:


$$\frac{\partial EQT}{\partial \hat{\beta}_0} = 0 \Rightarrow \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

$$\frac{\partial EQT}{\partial \hat{\beta}_1} = 0 \Rightarrow \hat{\beta}_1 = \frac{\sum x_i y_i}{\sum x_i^2}$$

Em que $x_i = (X_i - \bar{X})$ e $y_i = (Y_i - \bar{Y})$

Regressão Linear Múltipla:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$$



$$EQT = \sum_{i=1}^n (Y_i - (\hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \hat{\beta}_2 X_{2i}))^2$$

Minimizando EQT:

$$\frac{\partial EQT}{\partial \hat{\beta}_0} = 0 \Rightarrow \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}_1 - \hat{\beta}_2 \bar{X}_2$$

$$\frac{\partial EQT}{\partial \hat{\beta}_1} = 0 \Rightarrow \hat{\beta}_1 = \frac{(\sum y_i x_{1i})(\sum x_{2i}^2) - (\sum y_i x_{2i})(\sum x_{1i} x_{2i})}{(\sum x_{1i}^2)(\sum x_{2i}^2) - (\sum x_{1i} x_{2i})^2}$$

$$\frac{\partial EQT}{\partial \hat{\beta}_2} = 0 \Rightarrow \hat{\beta}_2 = \frac{(\sum y_i x_{2i})(\sum x_{1i}^2) - (\sum y_i x_{1i})(\sum x_{1i} x_{2i})}{(\sum x_{1i}^2)(\sum x_{2i}^2) - (\sum x_{1i} x_{2i})^2}$$

Modelo de Regressão Múltipla

Em um modelo de regressão múltipla, uma variável dependente Y_i está relacionada com duas ou mais variáveis independentes X_{ji} :

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + u_i$$

sendo:

β_0 é o valor esperado de Y quando todas as variáveis independentes forem nulas;

β_1 é a variação esperada em Y dado um incremento em X_1 , mantendo-se constante todas as demais variáveis independentes;

...

β_k é a variação esperada em Y dado um incremento em X_k , mantendo-se constante todas as demais variáveis independentes;

u_i é o erro não explicado pelo modelo;

Utilizando a forma matricial, temos:

$$\mathbf{y} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}; \quad \mathbf{X} = \begin{bmatrix} 1 & X_{11} & X_{21} & \Lambda & X_{k1} \\ 1 & X_{12} & X_{22} & \Lambda & X_{k2} \\ \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda \\ 1 & X_{1n} & X_{2n} & \Lambda & X_{kn} \end{bmatrix}; \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix}; \quad \mathbf{u} = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}$$

Ou,

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$$

Estimação dos Parâmetros do Modelo de Regressão Múltipla

Princípio dos mínimos quadrados: minimizar a soma dos quadrados das diferenças entre os valores observados Y_i e os valores esperados $E(Y_i)$.

Os valores esperados são estimados pelo modelo:

$$\hat{Y}_j = b_0 + b_1 X_{1j} + \Lambda + b_k X_{kj}$$

Ou, na forma matricial:

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{b}$$

Temos que: $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{X}\mathbf{b}$

A soma dos quadrados dos desvio é:

$$Z = \sum e_j^2 = \mathbf{e}'\mathbf{e} = (\mathbf{y}' - \mathbf{b}'\mathbf{X}')(\mathbf{y} - \mathbf{X}\mathbf{b}) = \mathbf{y}'\mathbf{y} - 2\mathbf{b}'\mathbf{X}'\mathbf{y} + \mathbf{b}'\mathbf{X}'\mathbf{X}\mathbf{b}$$

Diferenciando a função Z em relação aos parâmetros e igualando a zero, temos:

$$\mathbf{X}'\mathbf{X}\mathbf{b} - \mathbf{X}'\mathbf{y} = \mathbf{0} \Leftrightarrow \mathbf{X}'\mathbf{X}\mathbf{b} = \mathbf{X}'\mathbf{y}$$

Se $\mathbf{X}'\mathbf{X}$ é não singular ($\det(\mathbf{X}'\mathbf{X}) \neq 0$) temos:

$$\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

Pressupostos do Modelo

1. Linearidade do Modelo de Regressão: $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$

2. Amostragem Aleatória.

3. Ausência de Colineariedade Perfeita;

4. Erros possuem média zero:

$$E(u_j) = 0 \Leftrightarrow E(Y_j) = \beta_0 + \beta_1 X_{1j} + \cdots + \beta_k X_{kj}$$

5. Erros são homocedásticos:

$$Var(u_j) = \sigma^2 \Leftrightarrow Var(Y_j) = \sigma^2$$

6. Erros são não correlacionados:

$$\text{cov}(u_j, u_h) = \mathbf{0} \Leftrightarrow \text{cov}(Y_j, Y_h) = \mathbf{0}, j \neq h$$

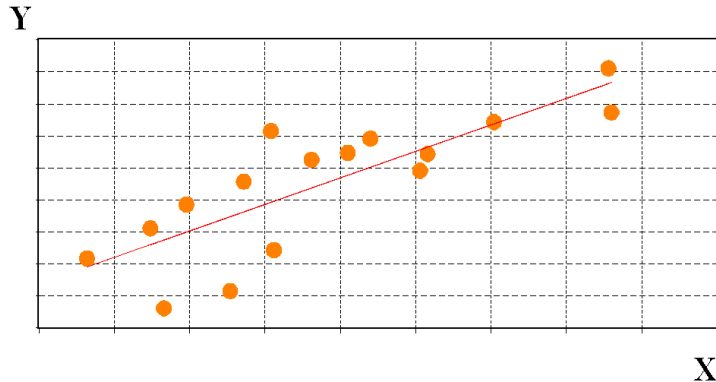
7. Erros são normalmente distribuídos:

$$u_j: N(0, \sigma^2) \Leftrightarrow Y_j: N(\mathbf{X}\mathbf{b}, \sigma^2)$$

Interpretação dos Coeficientes

Regressão Linear Simples:

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$



Tem-se que:

$E(Y|X = 0) = \beta_0$ Valor esperado de Y quando X é nulo.

$\frac{dY}{dX} = \beta$ Variação marginal esperada em Y para cada variação unitária em X .

Regressão Linear Múltipla:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$$

Tem-se que:

$$E(Y|X_1 = 0, X_2 = 0) = \beta_0$$

Valor esperado de Y quando ambos X_1 e X_2 são nulos.

$\frac{\partial Y}{\partial X_1} = \beta_1$ Variação marginal esperada em Y para cada variação unitária em X_1 , mantendo X_2 constante.

$\frac{\partial Y}{\partial X_2} = \beta_2$ Variação marginal esperada em Y para cada variação unitária em X_2 , mantendo X_1 constante.

- Coeficientes β 's captam o **efeito parcial** de uma variável independente sobre a variável dependente

Conceito de Efeito Parcial

Seja o modelo de RLM: $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$

- Pode-se demonstrar que o estimador de MQO para β_1 será:


$$\beta_1 = \frac{\sum_{i=1}^n \hat{r}_{i1} Y_i}{\sum_{i=1}^n \hat{r}_{i1}^2}$$

sendo \hat{r}_{i1} o resíduo do ajuste de MQO de X_1 em função de X_2 ;


- Processo similar a dois estágios de estimação:

1) X_1 em função de X_2 ;

2) Y em função dos resíduos do ajuste (1);



$$X_1 = \hat{\phi}_0 + \hat{\phi}_1 X_2 + \hat{r}_1$$



$$Y = \hat{\alpha}_1 + \hat{\beta}_1 \hat{r}_1 + \hat{e}_1$$

Propriedades dos Estimadores de MQO

1. A reta de regressão passa pelas médias de X e Y:

$$\bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{X} + e_i$$

2. A média dos resíduos é igual a zero:

$$\sum_{i=1}^n e_i = 0$$

3. A soma do produto dos resíduos pelos valores de X_i é igual a zero:

$$\sum_{i=1}^n e_i X_i = 0$$

4. A soma do produto dos resíduos pelos valores estimados de Y_i é igual a zero:

$$\sum_{i=1}^n e_i \hat{Y}_i = 0$$

Escalas de Medidas

- Mudanças nas escalas de medidas irão modificar os coeficientes;

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

$$Y_i = \beta_0 + \beta_1 X_i + u_i \quad \Rightarrow \quad \hat{\beta}_1 = \frac{\sum x_i y_i}{\sum x_i^2} \quad \hat{\alpha}^* = \bar{Y} - \hat{\beta}^* \bar{X} = \bar{Y} - \frac{1}{c} \hat{\beta}(c\bar{X}) = \bar{Y} - \hat{\beta} \bar{X}$$

- Se, por exemplo, multiplicarmos uma das variáveis pela constante c :


$$Y_i = \beta_0 + \beta_1 (cX_i) + u_i \quad \Rightarrow \quad \hat{\beta}_0 = \bar{Y} - \frac{1}{c} \hat{\beta}_1^* (c\bar{X}) = \bar{Y} - \hat{\beta}_1^* \bar{X}$$

$$\hat{\beta}_1^* = \frac{\sum c x_i y_i}{\sum (c x_i)^2} = \frac{1}{c} \frac{\sum x_i y_i}{\sum x_i^2} = \frac{1}{c} \beta_1$$

Neste exemplo, o intercepto mantém-se o mesmo e o coeficiente angular é dividido por c .


Linearidade nos Coeficientes

- Para que os estimadores de MQO sejam não tendenciosos, as relações devem ser lineares nos coeficientes;



Modelo é **linear nas variáveis**: todos os expoentes de Y e X são iguais a 1.

Modelo é **linear nos parâmetros**: os expoentes de β_0 e β_1 são iguais a 1.




Modelo **não é linear nas variáveis**: possui um expoente de X igual a 2.

Modelo é **linear nos parâmetros**: os expoentes de β_0 , β_1 e β_2 são iguais a 1.

Interpretação dos Coeficientes

- O conceito de *ceteris paribus* (tudo mais constante) nem sempre é válido em modelos não lineares nas variáveis;

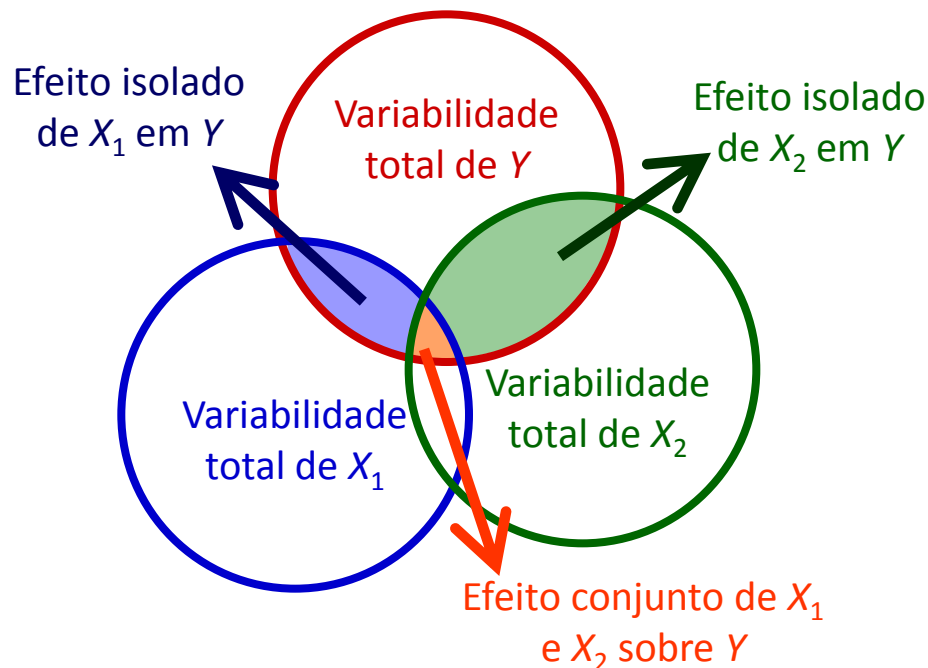


- No modelo quadrático, o efeito marginal de X em Y dependerá do valor de X :

$$\frac{dY}{dX} = \beta_1 + 2\beta_2 X$$

Análise de Variabilidade


- Variabilidade total de Y representa os valores que Y pode assumir;
- Parcela da variabilidade de Y pode ser explicada isoladamente pela variável independente X_1 , outra explicada isoladamente por X_2 e outra explicada conjuntamente por X_1 e X_2 ;
- Variabilidade não explicada por X será refletida nos erros do modelo de regressão;



Sabemos que $Y_i = \hat{Y}_i + e_i$ (1)

sendo

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i \text{ e } e_i = Y_i - \hat{Y}_i$$



Especificamente, essas somas são:

$$SQ_{Total} = \sum (Y_i - \bar{Y})^2 = \sum y_i^2$$

$$SQ_{Reg} = \sum (\hat{Y}_i - \bar{Y})^2 = \sum \hat{y}_i^2 = \hat{\beta}_1^2 \sum x_i^2 = \hat{\beta}_1 \sum x_i y_i$$

$$SQ_{Res} = \sum e_i^2 = \sum (Y_i - \hat{Y}_i)^2 = \sum y_i^2 - \hat{\beta}_1 \sum x_i y_i$$


Das equações acima:

$$SQ_{Total} = SQ_{Reg} + SQ_{Res}$$


Soma dos Quadrados

- Permitem estimar a qualidade do ajuste;
- Modelos adequados implicam variabilidade relativamente baixa dos resíduos ($SQRes$) e variabilidade relativamente alta do ajuste de regressão ($SQReg$);


$$STQ = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \mathbf{y}^T \mathbf{y} - n\bar{Y}^2$$



$$SQReg = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = \hat{\boldsymbol{\beta}}^T \mathbf{X}^T \mathbf{y} - n\bar{Y}^2$$



$$SQRes = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \mathbf{y}^T \mathbf{y} - \hat{\boldsymbol{\beta}}^T \mathbf{X}^T \mathbf{y}$$




Teste F

- Estima a significância do ajuste, ou seja, qual a probabilidade de erro (p) se afirmarmos que o modelo contribui para explicar a variabilidade da variável dependente (rejeitar H_0).

Dado o modelo: $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + u_i$

E as hipóteses: $\begin{cases} H_0: \beta_1 = \dots = \beta_k = 0 \\ H_1: \text{Pelo menos um } \beta_k \neq 0 \end{cases}$

$$F = \frac{SQ\text{Res}/k}{SQ\text{Res}/[n-(k+1)]}$$



Rejeitar H_0	Rejeitar H_0	Rejeitar H_0	Não Rejeitar H_0
$\beta_1 \neq 0$ $\beta_2 \neq 0$	$\beta_1 = 0$ $\beta_2 \neq 0$	$\beta_1 \neq 0$ $\beta_2 = 0$	$\beta_1 = 0$ $\beta_2 = 0$
X_1 e X_2 contribuem para explicar Y . H_0 deveria ser rejeitado	Apenas X_2 contribui para explicar Y . H_0 deveria ser rejeitado	Apenas X_1 contribui para explicar Y . H_0 deveria ser rejeitado	Nenhuma variável contribui para explicar Y . H_0 não deveria ser rejeitado

Tabela Anova - Definição

- Resume os resultados da Análise de Variância do modelo.
- Valores de p pequenos (usualmente menores que 5%) indicam que o modelo contribui significativamente para explicar a variabilidade da variável dependente ($R^2 > 0$);

Fonte	gl	SQ	QM	F	p
Regressão	k	$\hat{\boldsymbol{\beta}}^T \mathbf{X}^T \mathbf{y} - n\bar{Y}^2$	$\frac{\text{SQReg}}{k}$	$\frac{\text{QMReg}}{\text{QMRes}}$	valor p
Resíduos	$n - (k + 1)$	$\mathbf{y}^T \mathbf{y} - \hat{\boldsymbol{\beta}}^T \mathbf{X}^T \mathbf{y}$	$\frac{\text{SQRes}}{n - (k + 1)}$		
Total	$n - 1$	$\mathbf{y}^T \mathbf{y} - n\bar{Y}^2$			

Coeficiente de Determinação

Coeficiente de determinação R^2 :

$$R^2 = \frac{SQ_{Reg}}{SQ_{Total}} = 1 - \frac{SQ_{Res}}{SQ_{Total}}$$

o qual indica a proporção da variabilidade da variável dependente Y que é explicada pelo conjunto das k variáveis independentes do modelo de regressão X .

$$0 \leq R^2 \leq 1.$$

Coeficiente de Determinação Corrigido

Considerando os graus de liberdade das $SQRes$ e $SQTotal$, o coeficiente de determinação corrigido é definido por:

$$\bar{R}^2 = 1 - \frac{(n - 1)}{(n - 2)} (1 - R^2)$$

Propriedades Amostrais do Estimador de Mínimos Quadrados

1. Os estimadores de mínimos quadrados \mathbf{b} são variáveis aleatórias;
2. Admitindo que os erros sejam distribuídos normalmente, então Y também será uma variável aleatória distribuída normalmente;
3. Os estimadores \mathbf{b} também terão distribuições normais de probabilidade, pois são funções lineares de Y ;
4. Se os erros não são distribuídos normalmente, então os estimadores de mínimos quadrados têm distribuição aproximadamente normal em grandes amostras.

Teorema de Gauss-Markov:

Sob os pressupostos (1 - 6) do modelo de regressão múltipla:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + u_i$$

os estimadores de mínimos quadrados b_k são os melhores estimadores lineares não tendenciosos e de variância mínima de β_k .

Como os estimadores de mínimos quadrados são funções lineares da variável dependente, e sob o pressuposto 7, temos que os estimadores também são distribuídos normalmente:

$$b_k : N(E(b_k), Var(b_k))$$

Valor Médio dos Estimadores

Temos que:

$$\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y} \quad (1)$$

Substituindo $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$ em (1):

$$\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'(\mathbf{X}\boldsymbol{\beta} + \mathbf{u}) = \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{u} \quad (2)$$

Tomando o valor esperado:

$$E(\mathbf{b}) = \boldsymbol{\beta}$$

Variâncias e Covariâncias dos Estimadores

Por definição, a matriz de variâncias e covariâncias é dada por:

$$\text{Var_Cov}(b) = E[(\mathbf{b} - E(\mathbf{b}))]^2 = E[(\mathbf{b} - \boldsymbol{\beta})(\mathbf{b} - \boldsymbol{\beta})']$$

Do resultado (2):

$$\mathbf{b} - \boldsymbol{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{u}$$

Temos:

$$E[(\mathbf{b} - \boldsymbol{\beta})(\mathbf{b} - \boldsymbol{\beta})'] = E[(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{u}\mathbf{u}'\mathbf{X}'(\mathbf{X}'\mathbf{X})^{-1}] = (\mathbf{X}'\mathbf{X})^{-1} \sigma^2$$

sendo σ^2 é a variância do erro, sendo sua estimativa dada por:

$$S^2 = \hat{\sigma}^2 = \frac{SQRes}{(n - p)} = QMRes = \frac{\mathbf{e}'\mathbf{e}}{(n - p)}$$


Teste t

- Estima a significância de cada coeficiente do modelo, ou seja, qual a probabilidade de erro (p) se afirmarmos que a j -ésima variável independente contribui isoladamente para explicar a variabilidade da variável dependente (rejeitar H_0).

Dado o modelo: $Y_i = \beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki} + u_i$

E as hipóteses: $\begin{cases} H_0: \beta_j = 0 \\ H_1: \beta_j \neq 0 \end{cases}$

$$t = \hat{\beta}_j / S_{\hat{\beta}_j}$$



sendo:

$$S_{\hat{\beta}}^2 = (\mathbf{X}^T \mathbf{X})^{-1} \hat{\sigma}^2$$

e:

$$\hat{\sigma}^2 = \frac{\mathbf{y}^T \mathbf{y} - \hat{\beta}^T \mathbf{X}^T \mathbf{y}}{n - (k + 1)}$$

Rejeitar $\beta_1=0$ e $\beta_2=0$	Rejeitar apenas $\beta_2=0$	Rejeitar apenas $\beta_1=0$	Não Rejeitar $\beta_1=0$ e $\beta_2=0$
$\beta_1 \neq 0$ $\beta_2 \neq 0$	$\beta_1 = 0$ $\beta_2 \neq 0$	$\beta_1 \neq 0$ $\beta_2 = 0$	$\beta_1 = 0$ $\beta_2 = 0$
X_1 e X_2 contribuem para explicar Y . Os dois testes t deveriam ser rejeitados	Apenas X_2 contribui para explicar Y . $H_0: \beta_2=0$ deveria ser rejeitado	Apenas X_1 contribui para explicar Y . $H_0: \beta_1=0$ deveria ser rejeitado	Nenhuma variável contribui para explicar Y . Nenhum dos testes t deveria ser rejeitado.

Exercícios

- 1) A partir do arquivo *wage1.xlsx*:
 - a) Ajuste um modelo por MQO para a renda (*wage*) como função linear dos anos de educação (*educ*) e experiência profissional (*exper*);
 - b) Interprete os coeficientes e analise a significância das estimativas;
 - c) Verifique a necessidade de um termo quadrático para a experiência profissional;