

Heterocedasticidade

Definição, Conseqüências, Identificação e Correção

Profa. Rosângela Ballini

Bibliografia:

1. WOLDRIDGE, J.M. (2006). Introductory Econometrics: a Modern Approach. Cap. 8.

Teorema de Gauss-Markov

Para que os estimadores de MQO sejam os Melhores Estimadores Lineares Não Viesados (MELNV, ou BLUE):

- 1) O modelo de regressão é linear nos parâmetros;
- 2) Os valores de X são fixos em repetidas amostras;
- 3) Ausência de colinearidade perfeita;
- 4) $E(u_j|X_1, \dots, X_k) = 0$;
- 5) $Var(u_j|X_1, \dots, X_k) = \sigma^2$ constante;
- 6) $corr(u_i, u_j) = 0, i \neq j$;
- 7) O termo estocástico u_j se distribui normalmente.

Definição

A suposição de homocedasticidade implica que, condicional às variáveis explicativas, a variância do erro é constante. Ou seja,


$$\begin{aligned} \text{Var}(u_j | X_{1j}, X_{2j}, \dots, X_{kj}) = \\ = \sigma^2 \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & 1 \end{pmatrix} = \begin{pmatrix} \sigma^2 & 0 & 0 & \dots & 0 \\ 0 & \sigma^2 & 0 & \dots & 0 \\ 0 & 0 & \sigma^2 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & \sigma^2 \end{pmatrix} \end{aligned}$$

Definição

Considerando que as hipóteses de 1, 2, 3, 4 e 6 sejam válidas (ou seja, apenas a suposição 5 está sendo violada), heterocedasticidade ocorre quando a dispersão em torno da regressão se altera em função dos valores da(s) variável(eis) explanatória(s), ou seja,

$$\text{Var}(u_j | X_{1j}, X_{2j}, \dots, X_{kj}) = \begin{pmatrix} \sigma_1^2 & 0 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & 0 & \dots & 0 \\ 0 & 0 & \sigma_3^2 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & \sigma_n^2 \end{pmatrix}$$

Exemplo



Causas da heterocedasticidade

- 1 Natureza das variáveis: algumas relações apresentam tipicamente tendência à heterocedasticia.
- 2 Valores extremos: ocorrência de um valor extremo pode inflacionar a variabilidade em um determinado ponto do ajuste.
- 3 Falhas na especificação do modelo: heterocedasticidade pode ser devido à omissão de variáveis importantes do modelo ou forma funcional incorreta.

Consequências da Heterocedasticidade

Seja o modelo de regressão linear simples, com as variáveis dependente e independente centradas, ou seja, $y_j = (Y_j - \bar{Y})$ e $x_j = (X_j - \bar{X})$:

$$y_j = \beta_1 x_j + u_j \quad (1)$$

Estimador de β_1 :

$$b_1 = \frac{\sum x_j y_j}{\sum x_j^2} = \frac{\sum x_j (\beta_1 x_j + u_j)}{\sum x_j^2} = \beta_1 + \frac{\sum x_j u_j}{\sum x_j^2} \quad (2)$$

Valor médio de b_1 :

$$E(b_1) = \beta_1 + \frac{E(\sum x_j u_j)}{\sum x_j^2} = \beta_1 \quad (3)$$

Consequências para os Estimadores de MQO

Supondo o modelo (1) homocedástico, o cálculo da variância do estimador b_1 é dado por:

$$Var(b_1) = \frac{\sigma^2}{\sum x_j^2} \quad (4)$$

Para o caso de presença de heterocedasticidade, a variância do estimador b_1 é dada por:

$$Var(b_1) = \frac{\sum x_j^2 \sigma_j^2}{\left(\sum x_j^2\right)^2} \quad (5)$$

Consequências para os Estimadores de MQO

Na forma matricial, temos que os estimadores são dados por:

$$\hat{\beta}^{(MQO)} \stackrel{Hip.3}{=} (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \stackrel{Hip.1}{=} (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \mathbf{u}) = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}$$

Com valor médio dado por:

$$E[\hat{\beta}^{(MQO)}] = E\left[\beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\right] \stackrel{Hip.2}{=} \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'E[\mathbf{u}] \stackrel{Hip.4}{=} \beta$$

A hipótese de homocedasticidade (suposição 5) **NÃO** desempenha papel algum na demonstração de que os estimadores de MQO do vetor de parâmetros do modelo de regressão linear é não viesado e consistente.

Consequências para os Estimadores de MQO

Na forma matricial, para a variância:

$$\text{Var} \left(\hat{\beta}^{(MQO)} \right) = E \left[\left(\hat{\beta}^{(MQO)} - \beta \right) \left(\hat{\beta}^{(MQO)} - \beta \right)' \right] =$$

$$= E \left\{ \left[(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{u} \right] \left[(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{u} \right]' \right\} =$$

$$= \left\{ (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' E \{ \mathbf{u}'\mathbf{u} \} \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} \right\}$$






$$\text{Var} \left(\hat{\beta}^{(MQO)} \right) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' \Omega \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1}$$

Consequências para os Estimadores de MQO

- O **Teorema de Gauss-Markov**, que afirma que os estimadores de MQO são os melhores estimadores lineares não viesados (**BLUE**), depende de forma crucial da suposição de homocedasticidade. Na **presença da heterocedasticidade**, os estimadores de MQO **não são mais BLUE** e nem assintoticamente eficientes.

Identificação de Heterocedasticidade

1) Análise Gráfica: dispersão entre e_j^2 (ou e_j) e X ou \hat{Y} .



A partir dos dados `hprice.xlsx`, estime o modelo de regressão linear múltipla:

$$price = \beta_0 + \beta_1 lotsize + \beta_2 sqrft + \beta_3 bdrms + u$$

Faça o gráfico de dispersão dos resíduos em função das variáveis independentes e em relação aos valores estimados de *price*.

Identificação de Heterocedasticidade - Testes Paramétricos

2) Métodos Formais (Testes Paramétricos):

a) Teste de Breuch-Pagan;

b) Teste de White.

Testes de Hipótese para Detecção de Heterocedasticidade

Considere a Hipótese de Homocedasticidade:

$$\begin{aligned} H_0 : \text{Var}(u_i | x_{1i}, x_{2i}, \dots, x_{ki}) = \\ = E(u_i^2 | x_{1i}, x_{2i}, \dots, x_{ki}) = \sigma^2 \end{aligned} \quad (6)$$

Para H_0 ser rejeitada, precisamos encontrar relação entre o u^2 e variáveis explicativas.

Testes de Homocedasticidade - Teste Breuch-Pagan

Da eq (6), temos:

$$u_i^2 = \delta_0 + \delta_1 x_{1i} + \dots + \delta_k x_{ki} + \nu_i \quad (7)$$

em que ν é o termo de erro da regressão auxiliar.

Hipótese de Homocedasticidade:

$$H_0 : \delta_1 = \delta_2 = \dots = \delta_k = 0$$

a qual pode ser verificada utilizando teste LM (Multiplicador de Lagrange) ou teste F.

Testes de Homocedasticidade - Teste Breuch-Pagan

Como a variável resposta, no modelo (7), não é diretamente observada, teremos que estimá-la.

Ou seja, estime o modelo:

$$Y_j = \beta_0 + \beta_1 X_{1j} + \beta_2 X_{2j} + \dots + \beta_k X_{kj} + u_j$$

por MQO e obtenha os resíduos e_j e eleve ao quadrado e_j^2 .

A equação (7) será dada por:

$$e_j^2 = \delta_0 + \delta_1 X_{1j} + \dots + \delta_k X_{kj} + \nu_j \quad (8)$$

e obtenha o R-quadrado desta regressão R_{aux}^2 .

Testes de Homocedasticidade - Teste Breuch-Pagan

Construa a estatística F :

$$F = \frac{R_{aux}^2/(k)}{(1 - R_{aux}^2)/(n - k - 1)} \sim F_{(k, n-k-1)}$$

em que k é o número de regressores.

Ou calcule a estatística LM (Multiplicador de Lagrange):

$$LM = nR_{aux}^2 \sim \chi_k^2$$

- Rejeitamos H_0 quando o valor observado da estatística de teste for superior ao crítico.

Teste Breuch-Pagan – Exemplo

Considerando os dados do arquivo `hprice.xlsx`, estime o modelo:

$$price = \beta_0 + \beta_1 lotsize + \beta_2 sqrft + \beta_3 bdrms + u$$

e aplique o teste de Breush-Pagan.

No R use a função `bptest()`.

Teste de Homocedasticidade – Teste de White

White (1980)¹ motivado pelo fato de que a suposição

$$\text{Var}(u_i | x_{1i}, x_{2i}, \dots, x_{ki}) = \sigma^2, \quad i = 1, 2, \dots, n$$

poderia ser substituída pela suposição de que bastaria o erro ao quadrado, u^2 , ser não correlacionado com todas as variáveis explicativas, com os quadrados das variáveis explicativas e com todos os produtos cruzados entre as variáveis explicativas, escreveu seu clássico artigo.

¹White, H. A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity. *Econometrica*, vol. 48, p. 817–838, 1980

Teste de Homocedasticidade – Teste de White

Por exemplo, quando o modelo de interesse apresentar $k = 2$ variáveis explicativas:

$$Y_j = \beta_0 + \beta_1 X_{1j} + \beta_2 X_{2j} + u_j \quad (9)$$

O teste de White ficará baseado nos resultados da estimação do seguinte modelo de regressão auxiliar

$$e_j^2 = \alpha_0 + \alpha_1 X_{1j} + \alpha_2 X_{2j} + \alpha_3 X_{1j}^2 + \alpha_4 X_{2j}^2 + \alpha_5 X_{1j} X_{2j} + \nu_j \quad (10)$$

em que e_j é o resíduo da regressão (9).

Teste de Homocedasticidade – Teste de White

Neste caso, a hipótese nula de interesse seria

$$H_0 : \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = \alpha_5 = 0$$

a qual, segundo White (1980), pode ser testada usando:

$$LM = nR_{aux}^2 \sim \chi_5^2$$

em que R_{aux}^2 é o coeficiente de determinação da regressão auxiliar (10).

Teste de Homocedasticidade – Teste de White

- Comparado ao teste proposto por Breusch-Pagan, a equação auxiliar (10) envolve 3 regressores a mais.
- Dependendo do número de variáveis explicativas constantes do modelo original de interesse, a perda de graus de liberdade será bastante grande.
- É importante observar se o tamanho da amostra que estamos usando para a estimação é suficientemente grande para a aplicação de tal metodologia.

Teste de Homocedasticidade – Teste de White

Observações:

1. A equação auxiliar envolvida no teste pode ser útil na identificação da forma funcional da heterocedasticidade ou de erro de especificação, ou de ambos.
2. Para minimizar a perda de graus de liberdade, o teste pode ser conduzido utilizando a seguinte regressão auxiliar:

$$e_j^2 = \gamma_0 + \gamma_1 \hat{y}_j + \gamma_2 \hat{y}_j^2 + \nu$$

Exemplo – Teste de White

Considerando os dados do arquivo hprice.xlsx, estime o modelo:

$$price = \beta_0 + \beta_1 lotsize + \beta_2 sqrft + \beta_3 bdrms + u$$

e aplique o teste de White.

Heterocedasticidade

Verificado heterocedasticidade, deve-se:

1. Ou usar estimadores robustos
2. Ou aplicar Mínimos Quadrados Generalizados (MQG):
 - 2.1) Mínimos Quadrados Ponderados – σ_i^2 conhecida
 - 2.2) Mínimos Quadrados Generalizados Factíveis – σ_i^2 desconhecida

Estimadores Robustos

Recentemente, muito se tem desenvolvido com relação ao ajuste de erros padrões e estatísticas de testes para que os mesmos se tornem válidos na presença de heterocedasticidade.

Estes procedimentos são conhecidos como **ROBUSTOS** pois **são válidos**, pelo menos para grandes amostras, **sendo ou não a variância do erro constante**.

Estimadores Robustos

Suponha:

$$\text{Var}(\mathbf{u}|\mathbf{X}) = E(\mathbf{u}'\mathbf{u}|\mathbf{X}) = \sigma^2\Omega =$$

$$= \sigma^2 \begin{pmatrix} \omega_1 & & & & \\ & \omega_2 & & & \\ & & \omega_3 & & \\ \dots & \dots & \dots & \dots & \dots \\ & & & \omega_n & \end{pmatrix} = \begin{pmatrix} \sigma_1^2 & & & & \\ & \sigma_2^2 & & & \\ & & \sigma_3^2 & & \\ \dots & \dots & \dots & \dots & \dots \\ & & & \sigma_n^2 & \end{pmatrix}$$

em que $\sigma_i^2, i = 1, 2, \dots, n$ são parâmetros desconhecidos.

Estimadores Robustos

Supondo válidas as suposições do modelo de regressão, com exceção da suposição da variância constante, temos:

$$\text{Var} \left(\hat{\beta}^{(MQO)} \right) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\Omega\mathbf{X} (\mathbf{X}'\mathbf{X})^{-1}$$

Ou,

$$\text{Var} \left(\hat{\beta}^{(MQO)} \right) = (\mathbf{X}'\mathbf{X})^{-1} \left(\sum \sigma_i^2 \mathbf{x}_i \mathbf{x}_i' \right) (\mathbf{X}'\mathbf{X})^{-1}$$

Estimadores Robustos

White (1980) demonstrou que uma estimativa simples das quantidades desconhecidas pode ser obtida a partir do cálculo de e_i^2 (quadrado do resíduo de MQO), ou seja,

$$\widehat{Var}(\hat{\beta}^{(MQO)}) = (\mathbf{X}'\mathbf{X})^{-1} \left(\sum e_i^2 \mathbf{x}_i \mathbf{x}_i' \right) (\mathbf{X}'\mathbf{X})^{-1} \quad (11)$$

A raiz quadrada dos elementos da diagonal principal desta matriz teremos o que usualmente costuma se chamar de **erro-padrão devido a White (ou erro padrão robusto em relação à heterocedasticidade)**.

Estimadores Robustos

Observações:

1. O erro-padrão robusto pode ser maior ou menor do que o erro-padrão não robusto;
2. Usando um método de estimação robusto, a estatística de teste t também será robusta.
3. Os erros padrão robustos e as estatísticas t robustas são justificadas somente quando o tamanho da amostra se torna grande.

A partir dos dados `hprice.xlsx`, estime o modelo de regressão linear múltipla:

$$price = \beta_0 + \beta_1 lotsize + \beta_2 sqrft + \beta_3 bdrms + u$$

e estime os erros padrão robusto e análise o modelo.

Medidas Corretivas: Método dos Mínimos Quadrados Ponderados

Vamos considerar o modelo de regressão linear simples:

$$Y_j = \beta_0 + \beta_1 X_j + u_j \quad (12)$$

Haverá heterocedasticidade quando

$$\text{Var}(u_j) = E(u_j^2) = \sigma_j^2$$

a qual pode ser representada por:

$$\text{Var}(u_j) = E(u_j^2) = \sigma^2 h_j$$

em que h_j indica como o erro u varia para cada observação.

Se conhecemos h_j podemos corrigir o modelo pela equação:

$$\frac{Y_j}{\sqrt{h_j}} = \beta_0 \left(\frac{1}{\sqrt{h_j}} \right) + \beta_1 \left(\frac{X_j}{\sqrt{h_j}} \right) + \left(\frac{u_j}{\sqrt{h_j}} \right) \quad (13)$$

Quando fazemos essa transformação temos as seguintes características do termo de erro transformado $u_j^* = \frac{u_j}{\sqrt{h_j}}$:

$$\text{Var}(u_j^*) = E(u_j^*)^2 = E \left(\frac{u_j}{\sqrt{h_j}} \right)^2 = \frac{1}{h_j} E(u_j^2) = \sigma^2$$

pois $E(u_j^2) = \sigma^2 h_j$.

A variância do termo erro transformado u_j^* é homocedástica.

Exemplo - MQP

A partir dos dados `hprice.xlsx`, estime o modelo de regressão linear múltipla:

$$price = \beta_0 + \beta_1 lotsize + \beta_2 sqrft + \beta_3 bdrms + u$$

Assumindo que a heterocedasticidade é da forma $\sigma_i^2 = \sigma^2 h_i$, em que $h_i = lotsize_i$. Faça a correção do modelo usando esta forma funcional para a heterocedasticidade.

Procedimento MQG Factível para Corrigir a Heterocedasticidade

Caso os erros do modelo de regressão sejam heterocedásticos, o caso mais comum é aquele em que a **forma da heterocedasticidade é desconhecida**.

Sendo assim, precisamos encontrar uma estimativa para a função $h(\mathbf{x})$, que seja gerada a partir de um estimador com boas propriedades.

MQG Factível para Corrigir a Heterocedasticidade

Suponha que:

$$\text{Var}(u|X) = \sigma^2 \exp(\delta_0 + \delta_1 X_1 + \dots + \delta_k X_k) \quad (14)$$

Note que $h(\mathbf{x}) = \exp(\delta_0 + \delta_1 X_1 + \dots + \delta_k X_k) > 0$

Para a estimação dos δ_j reescreveremos (14) como:

$$u^2 = \sigma^2 \exp(\delta_0 + \delta_1 X_1 + \dots + \delta_k X_k) \nu$$

Tomando o logaritmo, temos:

$$\ln(u^2) = \alpha_0 + \delta_1 X_1 + \dots + \delta_k X_k + \textit{erro} \quad (15)$$

em que *erro* tem média zero e é independente de \mathbf{x} .

MQG Factível para Corrigir a Heterocedasticidade

Ao estimarmos os parâmetros de (15), conseguiremos uma estimativa para a função $h(\mathbf{x})$, que é obtida de

$$\hat{h}(\mathbf{x}) = \exp(\widehat{\ln(u^2)}) \quad (16)$$

Usamos (16) para encontrar as estimativas de MQP e os respectivos erros padrões do modelo de interesse.

Exemplo - MQP

A partir dos dados `hprice.xlsx`, estime o modelo de regressão linear múltipla:

$$price = \beta_0 + \beta_1 lotsize + \beta_2 sqrft + \beta_3 bdrms + u$$

Use MQG para fazer a correção da heterocedasticidade.

Medidas Corretivas: Transformação dos Dados

Uma transformação em log do tipo:

$$\ln Y_j = \beta_0 + \beta_1 \ln X_j + u_j \quad (17)$$

muitas vezes reduz a heterocedasticidade quando comparada com a regressão

$$Y_j = \beta_0 + \beta_1 X_j + u_j$$

Exemplo - MQP

A partir dos dados `hprice.xlsx`, estime o modelo de regressão linear múltipla:

$$\log(\text{price}) = \beta_0 + \beta_1 \log(\text{lotsize}) + \beta_2 \log(\text{sqrft}) + \beta_3 \text{bdrms} + u$$

Faça o teste de Breush-Pagan.

Também estime o modelo usando estimador robusto.